

Diskussions-Pipeline

Wie ein Gesprächszug entsteht und wie die Diskussion iteriert

Multi-Persona-Diskussionssimulator · Stand 12. August 2026


Was das System tut

Mehrere KI-Personas (*Experten*) diskutieren ein vom Nutzer gestelltes Thema. Ein *Moderator* — selbst ein LLM-Aufruf ohne Persona — vergibt das Rederecht. Pro Zug spricht genau eine Persona. Die Diskussion läuft selbsttätig weiter, bis sie an den Menschen übergibt oder gestoppt wird.

Zwei Kreisläufe greifen ineinander: ein **äußerer Job-Kreislauf**, der Zug für Zug neu anstößt, und eine **innere Pipeline aus acht Stufen**, die einen einzelnen Zug erzeugt.

Leitprinzip der Architektur. Der sichtbare Text ist die Wahrheit, und Struktur wird deterministisch erzwungen — nicht erhofft. Prompts formulieren die Absicht; PHP stellt sicher, dass sie eintritt. Dieses Prinzip stammt aus der Messung: In 52 von 58 protokollierten Aufrufen stand eine als *harte Regel* markierte Kürzungsanweisung im Prompt, und kein einziger Beitrag hielt sie ein.

1. Der äußere Kreislauf — wie die Diskussion iteriert




- Der Job **startet sich selbst neu** — es gibt keinen zentralen Scheduler. Jeder Zug stellt den nächsten mit Verzögerung in die Queue.
- Die Verzögerung ist zugleich der Countdown, den das Frontend anzeigt. Sie ist nur dann > 0 , wenn tatsächlich ein Folgezug eingeplant wurde.
- Nach einer Übergabe läuft nichts weiter, bis der Mensch schreibt. Genau *ein* Nutzer wird gefragt: der Autor der offenen Nachricht, sonst der Projekt-Eigentümer.

2. Ein Zug — die acht Stufen

Jede Stufe darf abbrechen; dann endet der Zug vorzeitig.

■ Moderator-LLM ■ Agenten-LLM ■ deterministisch ■ Zustand



3. Die LLM-Aufrufe

Pro Zug fallen typischerweise vier bis sechs Aufrufe an.

Label	Modell	Vorlage	Ausgabevertrag
moderator:route	schnell	moderator/route	JSON-Schema (erzwungen)
think:<id>	stark	agent/think	Marker-Blöcke
moderator:select	schnell	moderator/select	JSON-Schema (erzwungen)
speak:<id>	schnell	agent/speak	Freitext + Steuerzeile
moderator:closure	schnell	moderator/closure	JSON-Schema (erzwungen)
summarizer:...	stark	shorten-chat	reiner Fließtext

Die THINK-Aufrufe laufen **nebenläufig**. Ein zusätzlicher Kandidat kostet daher Tokens, aber keine Wartezeit. Das wird ausgenutzt: Die Persona mit dem größten Gedächtnis-Rückstand hängt sich jeden Zug an den Stapel, ohne sprechen zu dürfen.

Warum speak als Einziger Freitext bleibt

Die Moderator-Aufrufe liefern JSON mit erzwungenem Schema — Aufzählungswerte und Pflichtfelder können gar nicht mehr fehlen. Für **speak** wäre das ebenfalls möglich, ist aber bewusst *nicht* umgesetzt: Der JSON-Modus verschlechtert die deutsche Prosa, und die Transkripte sind Studienmaterial. Die Verlässlichkeit kommt dort stattdessen aus dem nachgelagerten Abgleich.

Der Steuerungs-Anhang von speak

... sichtbarer Beitrag ...

---STEUERUNG---

ADRESSAT: E7 oder none

PAARTYP: Frage→Antwort | Ansprache→Reaktion | Beitrag→Diskussion | Synthese→Diskussion

Dieser Anhang ist unzuverlässig: In den protokollierten Läufen fehlte er in rund einem Fünftel der jüngsten Züge ganz, und in weiteren Fällen stand **ADRESSAT: none**, während die Prosa eine benannte Person direkt fragte. Deshalb sitzt dahinter der **SpeakTrailerResolver**.


4. Die deterministischen Wächter

Alles hier läuft **ohne LLM**. Jede dieser Regeln existiert, weil eine Prompt-Regel allein sie nachweislich nicht durchgesetzt hat.

Wächter	Wirkung
Pending-User-Klammer	Solange eine Nutzernachricht unbeantwortet ist, kann <i>nie</i> an den Nutzer übergeben werden. Verhindert „jetzt bist du dran“ als Antwort auf eine Frage.
Abkühlphase	Nach einer Übergabe zwei Expertenzüge Sperre, damit nicht mehrere Übergaben aufeinander folgen.
Paar-Vorrang	Steht der Adressat eines offenen Paares zur Auswahl, gewinnt er.
Kein Back-to-Back	Niemand spricht zweimal direkt hintereinander — bleibt äußerste Regel, auch gegenüber dem Paar-Vorrang.
SpeakTrailerResolver	Fehlt der Adressat im Anhang, wird er aus der Prosa geborgen — aber nur, wenn der Text wirklich eine Frage stellt und genau eine Person nennt.
Nutzer-Vokativ-Filter	Entfernt „ <i>admin</i> , ...“ am Satzanfang oder „..., <i>admin</i> .“ am Ende, wenn der Zug gar nicht an den Menschen gerichtet war.
Abgleich beim Speichern	Widerspricht die Absicht des Moderators dem, was der Text tut, gewinnt der Text .
Reaktionskadenz	Plant regelmäßig einen kurzen Reaktionszug ein, statt ihn zu erbitten.
Gedächtnis-Zusammenführung	Ein Block, den ein THINK auslöst, wird aus dem alten Gedächtnis übernommen statt gelöscht.

5. Adjazenzpaare — wie ein Paar öffnet und schließt

Ein Adjazenzpaar ist die kleinste Gesprächseinheit: Frage→Antwort, Ansprache→Reaktion. Der erste Teil macht den zweiten *konditionell relevant* — sein Ausbleiben fällt auf. Die Abschlussrate offener Paare ist ein strukturelles Natürlichkeitsmaß.



- Ein Zug darf gleichzeitig **schließen und öffnen**. Beide Enden werden gespeichert, damit die Kette erlaubt bleibt, das Paar aber erkennbar ist.
- Die Verknüpfung setzt PHP, nicht das Modell: Wer Adressat eines offenen Paares ist und spricht, schließt es.
- Der Speak-Prompt bekommt die **wörtliche Frage** vorgelegt — mit dem ausdrücklichen Hinweis, sie nicht nachzuerzählen. Ohne diesen Hinweis gab das Modell die Frage paraphrasiert als „Antwort“ zurück.

6. Was zwischen den Zügen bestehen bleibt

Ort	Inhalt
<code>summaries</code>	Das Gedächtnis je (Projekt, Persona) als Markerblöcke: ein Block pro Teilnehmer, [OFFENE_FRAGEN], [STAND]. Dazu ein Wasserzeichen, bis zu welcher Nachricht es gepflegt ist.
<code>messages</code>	Paartyp, Adressat (ausgehend), Antwort-Verknüpfung (eingehend).
<code>projects.settings</code>	Sprecherhistorie, Schweigezähler, Eröffnungen, Agenda-Phase, verdichteter Verlauf, aktuelle Nutzerfrage, Abkühlzähler, Reaktionskadenz, behandelte und erledigte Punkte.
<code>job_logs</code> , <code>prompt_logs</code>	Jeder LLM-Aufruf mit Prompt, Antwort und Laufzeit — die Grundlage jeder Auswertung.

Das Gedächtnis der Personas

- **Nur wer denkt, erinnert sich.** Deshalb hängt sich pro Zug die Persona mit dem größten Rückstand an den ohnehin nebenläufigen THINK-Stapel — ohne Rederecht. Ohne das hielten selten gewählte Personas nach 80 Nachrichten noch ein Gedächtnis von 35 Zeichen.
- **Zusammenführen statt überschreiben.** Vergisst ein THINK einen Block, bleibt der alte erhalten.

- **Fragen liegen beim Gefragten.** Wird jemand gefragt, landet die Frage deterministisch in *seinem* [OFFENE_FRAGEN] — nicht nur im Gedächtnis des Fragenden. Sie wird gelöscht, sobald das Paar wirklich geschlossen ist.
- **Eine Quelle für die Nutzerfrage.** Der Block wird bei jedem Schreiben aus `projects.settings` gestempelt, damit die Personas nicht auseinanderdriften.

Reaktionszüge

Damit die Runde nicht nur Fachnotizen austauscht, plant der Moderator regelmäßig einen kurzen Reaktionszug ein. Dabei entfallen im Speak-Prompt genau die drei Blöcke, die Länge erzeugen (Substanz, kein Echo, kein Kreisen); stattdessen gilt eine Ein-bis-zwei-Satz-Regel mit Gesprächswendungen, dazu ein echtes Token-Limit.

Typisches Ergebnis eines solchen Zuges:

„Sophie, dein Punkt zu den Metriken trifft den Kern. Für den Pilot setze ich die Zielwerte wie folgt — wie siehst du das, Lena?“

7. Nachmessen

Beide Werkzeuge laufen ohne Frontend und ohne Queue.

`php artisan spec:gen-message <id> --turns=N`

Führt N Züge synchron aus und gibt danach die Strukturkennzahlen aus. Mit `--metrics` nur auswerten, ohne zu generieren.

`php artisan replay:prompt-logs`

Spielt die protokollierten `speak`-Antworten erneut durch Parser und Abgleich — keine API-Aufrufe. Macht eine Prompt-Änderung vorher/nachher vergleichbar.

Kennzahl	Was sie zeigt
Abschlussrate offener Paare	Anteil der Fragen, die eine verknüpfte Antwort bekommen haben. Strukturelles Natürlichkeitsmaß.
Antwort nennt den Frager	Ob das Paar für einen Leser <i>erkennbar</i> ist, nicht nur in der Datenbank steht.
Verhältnis Paare zu Übergaben	Ob die Runde untereinander diskutiert oder ständig zum Menschen zurückfällt.
Gini der Redeanteile	0 = alle gleich oft, 1 = eine Persona hält das Wort.
Reaktionsmarker-Quote	Anteil der Beiträge mit einer echten Gesprächswendung statt reiner Darlegung.
Median-Länge	Ob die Runde redet oder Aufsätze schreibt.
Gedächtnis-Rückstand	Wie viele Nachrichten eine Persona hinterherhinkt.

Quelle im Code: `app/Services/PromptingPipeline/`. Stufen unter `Stages/`, Dienste unter `Support/`, Vorlagen unter `resources/views/prompts/`. Stellschrauben in `config/discussion.php`. Messung: `php artisan spec:gen-message <id> --turns=N` und `php artisan replay:prompt-logs`.