

Relevanz der Thesis: Statuseffekt, Architektur oder Modell?

Einschätzung der Quellenlage auf Basis des Quellenarchivs (126 Quellen, davon 115 im Volltext geprüft) und einer ergänzenden Literaturrecherche. Jan-Niclas Loosen, Universität Trier. Stand: 16. September 2026.

1. Leitfrage

1. **Statuseffekt.** Derselbe Diskussionsaufbau, aber ein Agent trägt einen Status-Titel (etwa „CEO“). Verschiebt allein das seinen Redeanteil?
2. **Architektur.** Lässt sich dieser Effekt über den Sprecherwahl-Mechanismus verstärken, abschwächen oder beseitigen?
3. **Modell.** Oder hängt der Effekt am Modell, sodass die Architektur wenig ausrichtet?

Jede Quelle wurde auf fünf Punkte geprüft: Wird Status manipuliert? Wird Redeanteil pro Agent oder Rolle gemessen? Unterscheidet sich ein Status- oder Identitätseffekt je Modell? Verändert eine Strukturmaßnahme einen solchen Effekt? Wird Modell gegen Architektur direkt verglichen?

2. Kurzurteil

Die Arbeit ist relevant, und ihre Lücke lässt sich präzise benennen:

Kein Paper misst Turn-Anteil und Gesprächsanteil gemeinsam unter einer Status-Manipulation. Für jede der beiden Einheiten existiert jeweils nur ein einziger Datenpunkt, gewonnen unter einem einzigen Sprecherwahl-Mechanismus und ohne Vergleich über Modelle.

Die einzelnen Bausteine sind dagegen gut besetzt:

- Für **Menschen** ist der Effekt theoretisch begründet und meta-analytisch belegt: Zugewiesener Status geht mit mehr Sprechzeit einher.
- Bei **LLMs** sind Statuseffekte nachgewiesen, fast immer auf Konformität, Deferenz und Beharren, nicht auf den Redeanteil.
- Die **Modellabhängigkeit** solcher Effekte ist durchgängig groß, teils mit wechselndem Vorzeichen.
- **Strukturmaßnahmen** verändern Identitätseffekte messbar.

Die beiden Arbeiten, die dem Kern am nächsten kommen, sprechen *gegen* eine einfache Übertragung des menschlichen Musters. In Tak2026 erhält ein Agent mit dem Label „instructor“ unter Selbstmeldung per Priorität nur 14,5 % des Rederechts statt der bei Gleichverteilung erwarteten 33 %. In Deng2025 schreibt ein Leader unter fester Reihenfolge bei GPT-4o zwar in allen vier Prompt-Varianten mehr Wörter als die übrigen Agenten, signifikant ist das aber nur in einer. Beide Arbeiten testen jeweils nur einen Mechanismus und werten den Redeanteil nur nebenbei aus.

Daraus folgt: Die Frage ist offen, und ihr Ausgang ist es auch. Ein Nulleffekt oder ein umgekehrter Effekt ist ausdrücklich plausibel. Das schwächt die Arbeit nicht, solange das Design beide Ausgänge als Befund trägt: Ob LLM-Agenten den menschlichen Statuseffekt reproduzieren, ist in beiden Richtungen eine Aussage.

3. Theoretische Verankerung

- **Berger1972** (Status Characteristics Theory): Äußere Statusmerkmale steuern über Leistungserwartungen, wer sich beteiligt und wer Einfluss bekommt, auch wenn das Merkmal für die Aufgabe irrelevant ist. Ein Titel wie „CEO“ ist genau so ein Merkmal.
- **SchmidMast2002** (Meta-Analyse): Dominanz und Sprechzeit hängen zusammen, stärker bei *zugewiesenen* Rollen als bei Persönlichkeit und stärker in größeren Gruppen. Beobachter schließen

aus Sprechzeit auf Dominanz.

- **Bales1951:** Auch in führungslosen Gruppen entsteht rasch eine Hierarchie der Beteiligung. Ungleichheit ist der Normalfall; Vergleichspunkt muss daher die Gruppe ohne Titel sein, nicht die Gleichverteilung.
- **MacLaren2020** (Babble Hypothesis): Sprechzeit sagt Führungsemergenz vorher. Das ist die Gegenrichtung und damit eine mögliche Rückkopplung.
- **Ridgeway1986, Islam2005:** Ob Status in Dominanz umgesetzt wird, hängt davon ab, ob die Hierarchie als legitim gilt.
- **Anderson2009:** Wer zuerst spricht, wirkt kompetenter; Gruppen übernehmen in 94 % der Fälle die zuerst genannte Antwort. Position und Reihenfolge sind eigene Effekte.
- **Woolley2010, Riedl2021:** Gleich verteilte Beteiligung geht mit besserer Gruppenleistung einher. Der Befund ist umstritten und taugt als Motivation, nicht als Prämisse.
- **Rose2020:** Der Gini-Koeffizient der Redezeit ist von der Gruppengröße verzerrt.

Barkett2026 überträgt die Expectation States Theory auf LLMs: Bei gleicher Fähigkeit entsteht eine Deferenz-Asymmetrie von 35 pp, allerdings nur mit ausdrücklicher Vorrang-Anweisung; reine Credentials erzeugen 6 % (n. s.). Bei ungleicher Fähigkeit überdeckt diese den Status-Cue.

4. Befund 1: Statuseffekte bei LLMs, fast nie auf den Redeanteil

Arbeit	Manipulation	Befund (Zielgröße)
Tak2026, Anh. H	„instructor“- gegen „student“-Label, Selbstmeldung per Priorität 1–5, Dreiergruppen	Rederecht: Instructor 14,5 % statt 33 %; Gebote gleichauf (2,70 gegen 2,73). Der Scheduler gleicht Beteiligung standardmäßig aus
Deng2025	Zufällig bestimmter Leader, Vierergruppe, Round Robin, GPT-4o	Wortzahl: Leader in allen vier Prompts vorn, signifikant nur in einem ($p = .01$; sonst .07 bis .30). Menschen: 1076,9 gegen 645,0 ($p = .00$)
Choi2026	Nur der Rollename des zweiten Agenten ändert sich	Anfangsübereinstimmung 91,3 % (neutral) gegen 53,8–73,8 % (Autorität); die Autorität beharrt
Barkett2026	Credentials, mit und ohne Vorrang-Anweisung	Deferenz; siehe oben
Vijjini2026	Machtgefälle per Persona in Dyaden	Koordination, Überzeugung, Befolgung; modell- und größenabhängig
Qu2026 (No-Speaker)	Quellenrahmung bis Experten-Panel	Konformität +1,6 bis +29,7 pp je Modell
Mammen2026	Vier Expertise-Stufen	Übernahme steigt stufenweise mit der Expertise
Bajaj2026	Experten, Freunde, LLMs als Quelle	Experten $\beta = 1,00$, Freunde n. s.
Choi2025, Anh. H	Doctor- gegen Assistant-Persona	Nullbefund (0,52 gegen 0,64)
Wang2025	Expertise-Angabe des Nutzers	Nullbefund (höchstens 4,4 pp)
Klieger2024	CEO-, PM-, Dev-Agenten, freie Selbstauswahl	CEO macht 2–4-mal häufiger Vorschläge (Anteil an eigenen Nachrichten); Titel und Aufgabe vermengt

Nur Tak2026 und Deng2025 messen etwas, das dem Redeanteil entspricht, jeweils unter einem einzigen Mechanismus, einem Label und als Nebenanalyse. In Tak2026 kann zudem der ausgleichende Scheduler einen Teil der fehlenden Dominanz erklären; das Paper trennt das nicht.

5. Befund 2: Redeanteil unter Status ist in beiden Einheiten nur je einmal gemessen

Der Redeanteil lässt sich in zwei Einheiten fassen, die auseinanderlaufen können: der **Turn-Anteil** (wie oft ein Agent das Wort bekommt) und der **Gesprächsanteil** (wie viel Text er beiträgt). Bei Menschen hängen beide eng zusammen (MacLaren2020). Für jede Einheit sieht die Lage anders aus.

Turn-Anteil

Arbeit	Was gemessen wird	Status?	Mechanismen
Tak2026	Anteil am Rederecht je Agent	ja: „instructor“ 14,5 % statt 33 %	einer: Gebote mit Ausgleichsregel
Bailis2024	Beiträge je Runde als Gruppensumme	nein, Team × Modell	einer: Bidding
Eckhaus2025	Nachrichten je Phase	nein	einer, ein Agent unter Menschen
Nonomura2025	Monopolisierung nur als qualitatives Beispiel	nein	drei, aber nicht auf Turns ausgewertet
Yang2026	ob ein Agent das Wort erhält	nein	zwei (Bewerbung, Rotation), keine Verteilung je Agent
Venkatesh2026	Konzentration von Koordinationseignissen	nein	Topologien, keine Chat-Turns

Genau ein Datenpunkt verbindet Status und Turn-Anteil, und er zeigt ein umgekehrtes Vorzeichen. Dass die Verteilung der Turns modellabhängig ist, ist belegt, aber nur ohne Status (Turn-Entropie in Tak2026: Menschen .96, Qwen-4B/14B .94–.98, Qwen-32B .80–.83, gpt-oss-20b .87–.90).

Gesprächsanteil

Arbeit	Was gemessen wird	Status?	Mechanismen
Deng2025	Wortzahl Leader gegen Nicht-Leader	ja: Tendenz, meist n. s.	einer: Round Robin; nur GPT-4o, nur Anhang
Becker2024	Tokens je Nachricht nach Position	nein	mehrere Paradigmen, Turns aber fest
Zhang2026 (Post-Training)	Antwortlänge je Checkpoint	nein	einer: Zwei-Agenten-Folge
Bailis2024	„GPT-4 spricht länger“	nein	nur qualitativ
Ma2025, Samanta2026, Ye2024	Länge als Einfluss auf Richter	nein	Richter-Architekturen, kein Gesprächsanteil

Auch hier verbindet genau ein Datenpunkt Status und Länge, und zwar ausgerechnet unter der Pipeline, in der die Turns fest sind. Unter freier Sprecherwahl hat niemand die Länge der Beiträge unter Status gemessen.

Was vollständig offen ist

1. **Beide Einheiten gemeinsam.** Kein Paper erhebt Turn- und Gesprächsanteil für dieselben Agenten. Ob ein betitelter Agent seltener, aber länger spricht, ist nirgends untersucht. Tak2026

und Deng2025 deuten zusammengenommen in diese Richtung, stammen aber aus verschiedenen Settings.

2. **Status × Mechanismus.** Für keine der beiden Einheiten liegt mehr als ein Mechanismus vor. Tak2026 benennt den Raum der Floor-Control-Mechanismen selbst als „largely unexplored“.
3. **Status × Modell.** Für keine der beiden Einheiten wird der Statuseffekt über mehrere Modelle verglichen: Deng2025 testet nur GPT-4o, Tak2026 wertet das Label nicht je Modell aus.

Die zwei Einheiten sind damit nicht nur eine Messentscheidung, sondern ein eigener Beitrag: Ihr Zusammenspiel unter Status ist die am wenigsten erforschte Stelle der gesamten Frage.

Weitere Arbeiten zur Beteiligung ohne Status: Zhang2026 (Preferential Attachment) zeigt, dass funktionale Rollen im System-Prompt die Kommunikationsprominenz dauerhaft verschieben, sogar gegen ein stärkeres Basismodell; Quan2025 gibt Gesprächigkeit per Persona vor, wertet sie aber nicht aus.

6. Befund 3: Architektur verändert Identitätseffekte

- **Choi2025:** Anonymisierung beseitigt den Identitätsbias weitgehend (Qwen-32B, MMLU: 0,608 → 0,024).
- **Dietrich2026:** Wird Identität nur in einem Kanal verborgen, heben sich gegenläufige Effekte auf und es entsteht ein scheinbarer Nulleffekt. Keiner der Effekte ist signifikant; die Arbeit liefert eine Designregel, keinen gesicherten Befund.
- **Tian2025:** Sichtbare Autorschaft erzeugt Selbst-Voting, sichtbare Stimmen Herdenverhalten.
- **Chae2026:** Schon die Angabe „eigener“ oder „fremder“ Beitrag verschiebt Richterurteile bei identischem Inhalt.
- **Ma2025:** Debatte unter Richtern verstärkt Positions-, Längen- und Mehrheits-Bias; ein Meta-Richter ist robuster.
- **Cemri2025:** In ChatDev wurde Hierarchie gezielt als Fehlerbehebung eingebaut (nur Vorgesetzte beenden das Gespräch). Statusrollen sind in realen Frameworks Architekturentscheidungen.

7. Befund 4: Modellabhängigkeit ist die Regel

- **Qu2026 (No-Speaker):** derselbe Experten-Cue +1,6 bis +29,7 pp je Modell.
- **Weng2025:** Alle 11 Modelle passen sich an, die Anfälligkeit hängt deutlich von Modell und Größe ab.
- **Zhang2026 (Post-Training):** Dieselbe Rollenvorgabe verschiebt Hedging bei Llama um −15 %, bei Qwen um +13 %.
- **Nama2026, Tak2026, Eckhaus2025:** Schon die Grundneigung zu sprechen und das Bietverhalten unterscheiden sich systematisch zwischen Modellen.
- **Seyedin2026:** In modellhomogenen Teams bleibt ein gewählter Manager dauerhaft im Amt, Wechsel gibt es nur in gemischten Teams.
- **Gao2026:** Ein Orchestrator delegiert überproportional an Modelle des eigenen Anbieters (bis 3,65-fach). Die Orchestrator-Bedingung ist keine neutrale Referenz.

8. Befund 5: Modell gegen Architektur hängt von der Zielgröße ab

Arbeit	Was dominiert	Zielgröße
Wu2025	Modell; Strukturfaktoren klein, Teamgröße aber signifikant	Accuracy
Kraidia2026	Modell	Manipulierbarkeit
Myakala2026	Modell (RAG +0,02)	Drift-Resistenz
Barkett2026	Fähigkeit vor Status-Cue	Deferenz
Zhu2026	Architektur (0,46 → 0,75)	Rollenkonsistenz
(MENTOR)		
Nama2026	Training vor Modell	Sprechneigung
Hu2026	Struktur 40,6 % gegen Modell 2,7 % erklärte Varianz bei der Breite; Modell 31,4 % gegen Struktur 11,4 % bei der Kohärenz	Diskussionsverlauf

In Wu2025 meint „debate order“ die Reihenfolge der besprochenen Rätselfiguren, nicht die Sprecherreihenfolge; die Arbeit ist daher kein Gegenbeleg für Sprecherwahl-Mechanismen. Hu2026 liefert das Analyseschema, das für den Redeanteil noch fehlt: die Zerlegung der erklärten Varianz nach Struktur, Modell und Wechselwirkung. Nebenbei zeigt Hu2026, dass eine Selbstmeldung per Score die Kreativität senkt; die Autoren vermuten, dass sie selbstsichere Agenten bevorzugt, messen das aber nicht.

9. Folgerungen für das Design

Jeder Mechanismus bietet dem Status einen anderen Einstiegspunkt

- **Round Robin:** Die Turn-Zahl ist fest; der Titel kann nur die Beitragslänge verändern. Nullpunkt für Turns, Replikation von Deng2025 für den Gesprächsanteil.
- **Select by score:** Der Titel kann den Selbst-Score anheben. Tak2026 zeigt, dass das nicht geschehen muss. Selbstbewertung ist als Auswahlkriterium unzuverlässig (Houde2025, Prakash2026).
- **Orchestrator-Selection:** Ein LLM-Selektor kann den betitelten Agenten bevorzugen; seine Auswahl ist selbst modellabhängig verzerrt (Gao2026, Ye2024).
- **Select by quality of proposal:** Der Titel wirkt nur, wenn der Richter ihn sieht. In der Bedingung ohne Status sieht er keinen; der Vergleich beider Bedingungen zeigt damit direkt, ob der Effekt über die Sichtbarkeit läuft. Richter bevorzugen wortreiche Beiträge (Samanta2026, Ma2025).

Konsequenzen

1. **Vollständige Matrix** aus Mechanismen und Statusbedingungen, damit der Statuseffekt je Mechanismus als Differenz derselben Zeile gemessen wird.
2. **Zwei Einheiten:** Turn-Anteil (Anteil an den Wortmeldungen) und Gesprächsanteil (Anteil am Textumfang, in Wörtern und Zeichen statt in modellabhängigen Tokens) je Agent, dazu Entropie und Gini auf Gruppenebene (Tak2026, Rose2020). Beide Einheiten können auseinanderlaufen: In Tak2026 sinkt der Turn-Anteil, in Deng2025 steigt bei festen Turns der Wortumfang.
3. **Modell als dritte Achse,** Teams innerhalb eines Laufs homogen, sonst misst der Titel Fähigkeit statt Status (Barkett2026, Seyedin2026).
4. **Kontrollbedingung mit gleich langem neutralem Zusatztext** (Qu2026) und Rotation

des Titels über alle Positionen (Anderson2009, Baltaji2024).

5. **Keine ausgleichende Logik im Scheduler**, sonst wird ein Statuseffekt von der Architektur selbst geglättet, wie womöglich in Tak2026 und Eckhaus2025.
6. **Nulleffekt einplanen**: Tak2026, Deng2025, Choi2025 und Wang2025 machen ihn plausibel. Teststärke vorab abschätzen.

10. Nutzerstudie

Keine gefundene Studie prüft, ob ungleiche Beteiligung *zwischen mehreren KI-Agenten* Menschen stört. Houde2025 betrifft einen Agenten unter Menschen und misst Ideen, nicht Turns.

- **Song2024**: Mehrere Agenten mit gleichem Inhalt erzeugen normativen Druck; ab fünf Agenten tritt Reaktanz auf. Designvorlage: Inhalt fest, Verteilung variiert.
- **Parisi2026**: Nutzer empfinden LLM-Moderation als inklusiv, obwohl die gemessene Ungleichheit unverändert bleibt, und bevorzugen redselige Modelle. Selbstauskunft allein genügt nicht.
- **Alsobay2025**: Ein Moderator mit dem Auftrag, alle zu Wort kommen zu lassen, gleicht Beteiligung messbar aus, ohne die Entscheidungen zu verbessern.
- **Pareek2026, Lee2026, Yu2026**: Nutzer lesen Anzahl, Konsens und Gleichförmigkeit der Agenten, nicht deren innere Hierarchie; Rollenlabels wie „Kritiker“ wirkten kaum.
- **Samanta2026**: LLM-Bewerter stimmen mit Menschen kaum überein ($\kappa \approx 0,11-0,18$). Die Nutzerstudie braucht echte Versuchspersonen.
- **SchmidMast2002, Liu2024**: Beobachter schließen aus Sprechzeit auf Dominanz, Nutzer trauen autoritativen Personas mehr. Titel und Redeanteil müssen getrennt variiert werden.

11. Was weiterhin Druck macht

- **Der Kerneffekt kann ausbleiben oder sich umkehren** (Tak2026, Deng2025).
- **Richter- und Selektor-Biases** überlagern den Titel: LLM-Text (Liu2023), Autorität (Ye2024), Wortreichtum (Samanta2026), eigenes Modell (Gao2026), Absenderlabels (Chae2026). Sie gehören zur jeweiligen Bedingung und werden protokolliert.
- **Emergente Hierarchie** ohne Titel (Ji2026, Venkatesh2026, Bales1951).
- **Aufwand**: vier Mechanismen, zwei Statusbedingungen, mehrere Modelle, dazu Rotation und Themen.

12. Empfehlung

1. **Leitfrage**: „Reproduzieren LLM-Agenten den menschlichen Statuseffekt auf den Redeanteil, und hängt dessen Stärke eher am Sprecherwahl-Mechanismus oder am Modell?“
2. **Die Lücke eng formulieren**, wie im Kurzurteil, getrennt nach Turn- und Gesprächsanteil, und Tak2026 sowie Deng2025 als nächste Nachbarn offen diskutieren. Ihre Gegenbefunde sind Motivation, kein Hindernis.
3. **Theorie in die Einleitung**: Status Characteristics Theory und die Meta-Analyse zur Sprechzeit machen aus der Frage eine ableitbare Hypothese.
4. **Die Nutzerstudie als eigenständigen Beitrag führen**.

13. Einordnung

Dies ist eine Lesart der Quellenlage, kein Urteil des Betreuers. Die Aussagen zu den 115 Quellen mit Volltext beruhen auf gezielter Lektüre der einschlägigen Abschnitte. Bei den elf Quellen ohne frei zugänglichen Volltext, darunter die meisten sozialpsychologischen Klassiker, stützen sich die Angaben auf Abstracts und Sekundärquellen. Mehrere Archiv-Notizen weichen vom Volltext ab, am deutlichsten Qu2026 (Easier to Mislead), Houde2025, Nonomura2025, Bian2025, Li2025 und Park2023; diese sollten vor dem Zitieren korrigiert werden.