

Vorhabensübersicht

Statuseffekte auf den Redeanteil in Multi-Agenten-LLM-Diskussionen: Architektur oder Modell? Jan-Niclas Loosen, Universität Trier. Stand: 16. September 2026.

1. Das Vorhaben in einem Satz

Untersucht wird, ob ein Status-Titel wie „CEO“ den Redeanteil eines LLM-Agenten in einer Gruppendiskussion erhöht, wie es für Menschen gut belegt ist, und ob die Stärke dieses Effekts eher vom Sprecherwahl-Mechanismus oder vom verwendeten Modell abhängt.

Kein bisheriges Paper variiert einen Status-Titel kontrolliert und misst den Turn- und Gesprächsanteil unter mehreren Sprecherwahl-Mechanismen und Modellen. Die nächsten Nachbarn messen Status auf Konformität und Deferenz (Choi2026, Qu2026, Barkett2026) oder werten den Redeanteil unter einem einzigen Mechanismus nebenbei aus (Tak2026, Deng2025).

2. Theoretischer Rahmen und Hypothesen

Die Status Characteristics Theory (Berger1972) sagt voraus, dass äußere Statusmerkmale über Leistungserwartungen die Beteiligung steuern, auch wenn sie für die Aufgabe irrelevant sind. Eine Meta-Analyse (Schmid Mast2002) bestätigt den Zusammenhang von Dominanz und Sprechzeit, besonders bei zugewiesenen Rollen. Offen ist, ob LLM-Agenten dieses Muster reproduzieren. Die bisherigen Hinweise sind gemischt: In Tak2026 erhält ein „instructor“ unter Selbstmeldung nur 14,5 % des Rederechts statt 33 %; in Deng2025 schreibt ein Leader unter fester Reihenfolge tendenziell mehr, meist nicht signifikant.

H1 Statuseffekt. Unter freier Sprecherwahl weichen Turn-Anteil und Gesprächsanteil des betitelten Agenten von denen desselben Agenten ohne Titel ab. Gerichtete Erwartung nach der Theorie: nach oben. Unter Round Robin zeigt sich ein Effekt höchstens im Gesprächsanteil.

H2 Architektur moderiert. Die Größe des Statuseffekts unterscheidet sich zwischen den Mechanismen. Erwartung: am größten, wo der Titel direkt in die Auswahl eingeht (Orchestrator, Selbst-Score), am kleinsten unter Round Robin.

H3 Modell moderiert. Die Größe des Statuseffekts unterscheidet sich zwischen den Modellfamilien. Ob der Modell- oder der Mechanismusanteil an der erklärten Varianz größer ist, bleibt als offene Frage formuliert.

Alle drei Hypothesen tragen auch ein Nullergebnis: „LLM-Agenten reproduzieren den menschlichen Statuseffekt nicht“ beziehungsweise „die Architektur verändert ihn nicht“ sind eigenständige Befunde.

3. Versuchsdesign: eine vollständige Matrix

Alle Bedingungen werden in einer gekreuzten Matrix getestet. Jede Pipeline läuft einmal mit und einmal ohne Status, und zwar für jedes Modell.

Pipeline (Sprecherwahl)	mit Status	ohne Status
Round Robin	•	•
Select by score	•	•
Orchestrator-Selection	•	•
Select by quality of proposal	•	•

je Modellfamilie wiederholt: $4 \text{ Pipelines} \times 2 \text{ Statusbedingungen} \times 3 \text{ Modelle} = 24 \text{ Zellen}$

Lesart der Matrix.

- **Statuseffekt (H1)** je Pipeline: Differenz „mit“ minus „ohne“ in derselben Zeile.

- **Architektur (H2):** Unterschied dieser Differenzen zwischen den Zeilen.
- **Modell (H3):** Unterschied dieser Differenzen zwischen den Modellen.

3.1 Statusbedingungen

- **Mit Status:** Ein Agent der Gruppe trägt den Titel „CEO“, die übrigen einen gleichrangigen Rollennamen. Alle Agenten erhalten dieselben Aufgabeninformationen.
- **Ohne Status:** Derselbe Agent erhält statt des Titels einen neutralen Zusatztext gleicher Länge. Ohne diese Angleichung wäre der Effekt des Titels nicht vom Effekt des zusätzlichen Textes zu trennen (Qu2026).
- **Rotation:** Der betitelte Agent wechselt über alle Positionen der Gruppe, weil Position und Erstsprecherrolle eigene Effekte haben (Anderson2009, Baltaji2024, Kaesberg2025).

3.2 Pipelines

Pipeline	Umsetzung und Vorbild	Wie der Status wirken kann
Round Robin	Feste Rotation; EQUAL bei Nonomura2025, Setup von Deng2025	Nur über den Gesprächsanteil; Nullpunkt für den Turn-Anteil
Select by score	Jeder Agent meldet pro Schritt eine Sprechpriorität von 1 bis 5, die höchste spricht; Formate aus Tak2026, Bailis2024, Nonomura2025	Der Titel hebt die eigene Priorität. Selbstbewertung ist unzuverlässig (Houde2025, Prakash2026)
Orchestrator-Selection	Ein LLM-Selektor wählt pro Turn den nächsten Sprecher aus dem Verlauf; GroupChatManager in Wu2023	Der Selektor bevorzugt den Titel; seine Auswahl ist selbst modellabhängig verzerrt (Gao2026, Ye2024)
Select by quality of proposal	Alle Agenten schreiben einen Entwurf, ein Richtermodell bewertet und vergibt das Wort; Marandi2026	Der Titel wirkt nur, wenn der Richter ihn sieht; ohne Status sieht er keinen. Richter bevorzugen wortreiche Beiträge (Samanta2026, Ma2025)

Keine ausgleichende Logik. Tie-Breaks werden zufällig aufgelöst, nicht zugunsten seltener Sprecher. Eine eingebaute Balancierung würde einen Statuseffekt durch die Architektur selbst glätten; in Tak2026 und Eckhaus2025 ist das nicht auszuschließen.

3.3 Modelle und Gruppen

- **Drei Modellfamilien,** innerhalb eines Laufs homogen besetzt. Gemischte Teams würden Fähigkeit mit Status vermengen (Barkett2026, Seyedin2026).
- **Vier Agenten je Gruppe,** anschlussfähig an Deng2025; feste Gruppengröße, damit Ungleichheitsmaße vergleichbar bleiben (Rose2020).
- **Offene Entscheidungsdiskussionen** über mehrere Themen, festes Turn-Budget je Lauf.
- **Selektor- und Richtermodell:** Im Hauptdesign läuft der Selektor auf dem Modell des Teams, sein Bias gehört damit zum Modellfaktor. Eine kleine Gegenprobe mit festem Selektor prüft, wie viel des Modelleffekts auf den Selektor entfällt.

Architektonische Einschränkung. Der Vergleich findet innerhalb von Gruppenchats statt. In Multi-Agent-Debate sprechen alle Agenten simultan, der Redeanteil ist dort konstruktionsbedingt konstant.

4. Messinstrumentarium und Analyse

Der Redeanteil wird in **zwei Einheiten** gemessen, die auseinanderlaufen können: Der **Turn-Anteil** zählt, wie oft ein Agent das Wort bekommt; der **Gesprächsanteil** misst, wie viel Text er insgesamt beiträgt. Bei Menschen hängen beide eng zusammen (MacLaren2020), bei LLM-Agenten nicht zwingend: In Tak2026 sinkt der Turn-Anteil eines Agenten mit Label, in Deng2025 steigt bei festen Turns sein Wortumfang.

Kennzahl	Wozu	Herkunft
Turn-Anteil des betitelten Agenten	Anteil an allen Wortmeldungen; erste Zielgröße für H1 bis H3	Houtti2026, Eckhaus2025
Gesprächsanteil in Wörtern	Anteil am gesamten Textumfang; zweite Zielgröße, einzige unter Round Robin	Deng2025, Becker2024
Gesprächsanteil in Zeichen	Robustheitsprüfung der Wortzählung, unabhängig von Wortgrenzen und Formatierung	eigene Festlegung
Verhältnis von Gesprächs- zu Turn-Anteil	Zeigt, ob ein Agent seltener, aber länger spricht; bei Menschen hängen beide eng zusammen	MacLaren2020
Entropie der Turn-Verteilung je Lauf	Ungleichheit auf Gruppenebene	Tak2026, Fukuda2026
Gini-Koeffizient je Lauf	Zweites Gruppenmaß, bei fester Gruppengröße vergleichbar	Houtti2026, Rose2020
Priorität, Selektionsrate, Richterbewertung je Agent	Zeigt, über welchen Weg der Titel wirkt	pipelineintern
Übernahme der Position des betitelten Agenten	Nebenzielgröße; trennt Rederecht von Einfluss	Choi2026

Analyse. Gemischte Modelle mit dem Anteil des betitelten Agenten als abhängiger Variable, den Wechselwirkungen Status $\times$ Pipeline und Status $\times$ Modell sowie Thema und Lauf als zufälligen Effekten. Dazu eine Zerlegung der erklärten Varianz nach Pipeline, Modell und deren Wechselwirkung nach dem Schema von Hu2026. Eine Trefferquote für „richtige“ Sprecherwahl ist keine Zielgröße, da schon Menschen dabei uneins sind (Hilgert2025).

5. Kontrollen

- **Neutraler Zusatztext gleicher Länge** in der Bedingung ohne Status (Qu2026).
- **Grundneigung zu sprechen je Modell** aus den Läufen ohne Status, weil sie stark modellabhängig ist (Nama2026, Tak2026, Eckhaus2025).
- **Homogene Teams** gegen die Vermengung von Titel und Fähigkeit (Barkett2026).
- **Rotation des Titels** über alle Positionen.
- **Emergente Hierarchie:** Die Verteilung ohne Status wird selbst ausgewertet, da Ungleichheit auch ohne Titel entsteht (Bales1951, Ji2026, Venkatesh2026).
- **Vollständige Modellkonfiguration** berichten (Zhang2026): Checkpoint, Post-Training, Reasoning-Modus, Temperatur, Token-Limit, System-Prompt.
- **Messinstrument vorab festlegen:** Der Gesprächsanteil wird in Wörtern und in Zeichen gemessen, nicht in Modell-Tokens, weil sich die Tokenizer der Modellfamilien unterscheiden und der Modellvergleich sonst verzerrt wäre. Gezählt werden nur öffentliche Chat-Beiträge, keine Reasoning-Anteile und keine Nachrichten von Selektor oder Richter.
- **Ausfallraten je Modell** berichten statt stillschweigend zu filtern (Campedelli2024).

6. Nutzerstudie

Zweck. Klären, ob die in der Matrix entstehenden Verteilungen Menschen stören. Keine bisherige Studie prüft ungleiche Beteiligung zwischen mehreren KI-Agenten; Houde2025 betrifft einen Agenten unter Menschen und misst Ideen, nicht Turns.

- **Material:** Diskussionen aus der Matrix. Nach dem Vorbild von Song2024 bleibt der Inhalt möglichst gleich, variiert wird die Verteilung.
- **Bedingungen:** ausgewogen, dominant mit Titel, dominant ohne Titel. So lässt sich trennen, ob der Titel oder die Dominanz das Urteil treibt; Beobachter schließen aus Sprechzeit auf Dominanz (SchmidMast2002), Nutzer trauen autoritativen Personas mehr (Liu2024).
- **Messung:** wahrgenommene Dominanz, Vertrauen, Qualität des Ergebnisses, Gefühl des Ausgeschlossenenseins; dazu der Abgleich von Wahrnehmung und tatsächlicher Verteilung, weil beides auseinanderfällt (Parisi2026). Die Verteilung muss in der Darstellung sichtbar sein, da Nutzer innere Hierarchien sonst nicht wahrnehmen (Pareek2026).
- **Ablauf:** Within-subjects mit gegenbalancierten Themen, angelehnt an Houde2025.
- **Keine LLM-Bewerter als Ersatz:** Sie stimmen mit Menschen kaum überein und bevorzugen wortreiche Beiträge (Samanta2026).

Dass ausgewogene Redeanteile besser sind, wird nicht vorausgesetzt. Woolley2010 spricht dafür, der Befund ist aber umstritten; Alsobay2025 gleicht Beteiligung aus, ohne bessere Entscheidungen zu erzielen.

7. Was gebaut werden muss

- Eine Diskussionspipeline mit **austauschbarem Selektor** als klar abgegrenzter Komponente; alles Übrige bleibt über die Bedingungen identisch.
- Vier Selektorimplementierungen entsprechend der Matrix.
- Eine **Persona-Schicht**, die Titel, neutralen Zusatztext und Rotation steuert, ohne den übrigen Prompt zu verändern.
- **Protokollierung pro Turn:** Sprecher, Position, Statusbedingung, Länge in Wörtern und Zeichen (Reasoning-Anteile getrennt protokolliert), dazu Prioritäten, Selektorbegründung und Richterbewertung.
- Ein Auswertungsskript, das aus den Protokollen direkt Kennzahlen und Modelle erzeugt.

8. Abgrenzung

Arbeit	Status variiert?	Redeanteil gemessen?	Offene Stelle
Tak2026	Ja, Label „instructor“	Ja, Rederecht als Nebenanalyse	Ein Mechanismus mit ausgleichendem Scheduler; kleine Modelle, Logikaufgabe
Deng2025	Ja, Leader	Wortzahl	Round Robin fixiert die Turns; nur GPT-4o
Choi2026	Ja, Rollenname	Nein	Übereinstimmung, feste Alternation
Barkett2026	Ja, Credentials	Nein	Deferenz, Dyade
Vijjini2026	Ja, Machtgefälle	Nein	Koordination und Überzeugung, feste Reihenfolge

Qu2026	Ja, Quellen- rahmung	Nein	Konformität, Single-Turn
Zhang2026 (Pref. Attachment)	Funktionale Rollen	Kommunikations- prominenz	Netzwerk statt Gruppenchat, keine Status-Titel
Nonomura2025	Nein	Nein	Vergleicht Mechanismen, wertet Dialogqualität aus
Marandi2026	Nein	Nein	Ein Zug pro Agent je Runde fest
Dietrich2026	Identität	Nein	Modell $\times$ Anonymisierung auf Identity Bias
Hu2026	Nein	Nein	Varianzzerlegung Struktur $\times$ Modell, aber auf Kreativität
Houde2025	Nein	Ideenanteil	Ein Agent unter Menschen
Song2024	Nein	Nein	Mehrere Agenten, aber gleiche Beteiligung

9. Risiken

- **Der Statuseffekt bleibt aus oder kehrt sich um** (Tak2026, Deng2025, Choi2025, Wang2025). Berichtenswert, sofern Kontrollbedingung und Teststärke stimmen. Die Zahl der Läufe je Zelle wird nach einem Pilot per Poweranalyse festgelegt.
- **Selbstbewertung versagt** als Auswahlkriterium (Houde2025, Prakash2026). Die Schwäche gehört zur Pipeline und wird protokolliert, nicht repariert.
- **Richter- und Selektor-Biases** überlagern den Titel (Ye2024, Liu2023, Samanta2026, Gao2026, Chae2026). Dagegen stehen die pipelineinternen Messgrößen und die Gegenprobe mit festem Selektor.
- **Aufwand:** 24 Zellen, dazu Rotation, Themen und Wiederholungen. Token- und Laufzeitkosten je Bedingung werden als eigene Größe berichtet (Yehudai2025).
- **Trainierbarkeit** (Estornell2024, Nama2026): Verhalten ist per Training stärker veränderbar als per Architektur. Gehört ins Limitationskapitel.

10. Arbeitspakete

1. Pipeline mit austauschbarem Selektor, Persona-Schicht und Protokollierung, zunächst mit Round Robin.
2. Auswertungsskript und Kennzahlen, geprüft an künstlich erzeugten Extremfällen (ein Agent spricht immer, alle gleich oft).
3. Die übrigen drei Selektoren implementieren.
4. Pilot über alle Zellen mit wenigen Läufen: Funktionsprüfung, Grundneigung je Modell, Poweranalyse, Festlegung der Läufe je Zelle.
5. Die Matrix vollständig fahren.
6. Analyse mit Wechselwirkungen und Varianzzerlegung, Gegenprobe mit festem Selektor.
7. Nutzerstudie vorbereiten (Auswahl der Diskussionen, Fragebogen, Ethik) und durchführen.
8. Auswertung und Schreiben.

Die Messung steht vor dem ersten inhaltlichen Lauf. Weil alle Zellen im selben Design liegen, liefert schon die Round-Robin-Zeile zusammen mit einer freien Pipeline ein eigenständiges Ergebnis, falls spätere Pakete knapp werden.