Poweranalyse für die Hauptstudie Statuseffekt

A-priori-Bestimmung der Laufzahl je Mechanismus aus den Probereihen

1 Auf einen Blick

Für die Hauptstudie mit einem Modell (gpt-5-mini, alle Werte gelten nur dafür) werden **96 Paare je Mechanismus** benötigt. Das sind 192 Läufe je Mechanismus und **768 Läufe** für Score, Orchestrator, Quality und Blind-Quality, bei 100 Turns rund **1.310 $**.

PARAMETER	WERT	BEGRÜNDUNG
Signifikanzniveau	0,0125	Bonferroni für vier Tests, Teststärke 0,80, Abschnitt 2.1
Chatlänge	100 Turns	Chatlängen-Studie, Abschnitt 2.4
Kleinster relevanter Effekt	15 Prozentpunkte	Abschnitt 2.2, mit Betreuer klären
SD der Paardifferenzen	40 Prozentpunkte	Abschnitt 2.3, aus 40 Pilotpaaren
Benötigte Paare	83, balanciert 96	4 Themen × 4 Sitze × 6 Paare

2 Begründung der Parameter

Die Redeanteile innerhalb einer Diskussion addieren sich zu 100 %, deshalb ist der Lauf die Beobachtungseinheit und der Turn-Anteil der Fokuspersona die Zielgröße. Ein Paar sind zwei Läufe mit gleichem Thema, Sitz und Seed, mit und ohne Titel. Getestet wird die mittlere Paardifferenz mit dem gepaarten t-Test (Faul et al., 2007). Als Effektstärke dient Cohens d_z, die mittlere Differenz geteilt durch ihre Standardabweichung (Cohen, 1988).

2.1 Signifikanzniveau und Teststärke

Geprüft wird der Statuseffekt in Score, Orchestrator, Quality und Blind-Quality; Round Robin entfällt, weil der Turn-Anteil dort fest ist. Damit die Fehlerrate erster Art über vier Tests bei 5 % bleibt, wird das Niveau nach Bonferroni geviertelt (Dunn, 1961). Für die Teststärke gilt die Konvention von Cohen (1988) mit 0,80; bei 0,90 wären rund 105 Paare nötig.

2.2 Kleinster relevanter Effekt

Geplant wird mit dem kleinsten Effekt, der inhaltlich noch zählt, nicht mit dem beobachteten (Lakens et al., 2018; Lakens, 2022). Pilot-Effekte aus wenigen Paaren sind zu ungenau und führen zu systematisch zu kleinen Stichproben (Albers & Lakens, 2018). Angesetzt sind 15 Prozentpunkte, mehr als die Hälfte des fairen Anteils von 25 % in einer Vierergruppe.

Wichtig 15 Prozentpunkte sind gesetzt, nicht abgeleitet. Vor Studienbeginn mit dem Betreuer festlegen. Bei 20 reichen 48 Paare.

2.3 Streuung der Paardifferenzen

Die Streuung stammt aus dem Pilot, mit Aufschlag: Browne (1995) empfiehlt die obere Konfidenzgrenze statt der Punktschätzung, damit eine zu niedrig geschätzte Streuung die Teststärke nicht senkt.

MECHANISMUS	SITZ	PAARE	MITTLERE DIFFERENZ	SD
Score	1	4	+31,7	12,9
Orchestrator	1 und 3	12	+26,8	29,9
Quality	1 und 3	12	+47,9	32,5
Blind-Quality	1	4	+43,8	13,9

Turn-Anteil in Prozentpunkten, Läufe mit 60 Turns. Orchestrator und Quality liefen auf Sitz 1 und 3 (Sitztest), Score und Blind-Quality nur auf Sitz 1. 40 Paare aus 126 Läufen (Export vom 18. 10. 2026).

Gepoolt ergibt sich eine SD von rund 29 (Orchestrator 30, Quality 34). Die obere Grenze des 80-%-Konfidenzintervalls (SD mal Wurzel aus df durch das 20-%-Quantil der Chi-Quadrat-Verteilung) liegt bei 33 über alle Gruppen, 39 für den Orchestrator und 43 für Quality. Angesetzt ist **SD = 40**, weil Sitz 3 deutlich stärker streut als Sitz 1 (SD 46 bis 48 gegen 20 bis 26) und Score und Blind-Quality nur auf Sitz 1 gemessen sind.

2.4 Chatlänge von 100 Turns

Grundlage ist die Chatlängen-Studie vom 08. 10. 2026 mit sechs Läufen zu 100 Turns (Score, Orchestrator, Quality, je School und Office; etwa 11 $). Vorab festgelegtes Kriterium: Ein Lauf ist ab Turn T stabil, wenn sich der Anteil jedes Experten über die nächsten 10 Turns um höchstens 2 Prozentpunkte ändert und das bis zum Ende so bleibt.

- Nach 60 Turns erfüllen nur 4 von 24 Läufen das Kriterium, alle Extremfälle. Der Anteil des Titelträgers bewegt sich bis Turn 100 noch um 3 bis 7 Prozentpunkte, unter Quality systematisch nach oben (75 auf 82 % und 82 auf 89 %). 60 Turns würden den Effekt je Mechanismus verschieden stark unterschätzen.
- Nach 100 Turns ist der Wortanteil in allen sechs Läufen stabil (ab Turn 74 bis 90), der Turn-Anteil in vier (ab Turn 70 bis 90). Score und Orchestrator im Thema Office erreichen es nicht. Mit gleitendem Fenster von 20 Turns ist nur ein Lauf stabil. Ein Zufallsprozess mit denselben Endanteilen erfüllt das Kriterium in 43 bis 92 % der Fälle.

100 Turns sind deutlich stabiler als 60, aber nicht in jedem Lauf stabil. Festgelegt ist das noch nicht, die laufenden Reihen nutzen weiter 60. Original und Kopie sind keine Replikate, weil die Prompts zwischendurch geändert wurden.

3 Ergebnis und Sensitivität

SD DER PAARDIFFERENZEN	10 PP.	15 PP.	20 PP.
30 (Punktschätzung)	104	48	29
35	140	64	38
40 (gewählt)	182	83	48
45	229	104	60

Paare je Mechanismus bei Niveau 0,0125 (zweiseitig) und Teststärke 0,80, berechnet mit statsmodels wie in G*Power.

G*Power 3.1: t tests, matched pairs, A priori, Tails „Two“, Effect size dz 0.375, α err prob 0.0125, Power (1 – β err prob) 0.80. Ergebnis: Total sample size 83. Aufgerundet auf ein Vielfaches von 16 (Thema × Sitz) ergeben sich 96.

4 Einschränkungen

1. **Themen:** Der t-Test verallgemeinert nur auf die vier Themen. Für allgemeine Aussagen ist das Thema ein zufälliger Faktor (Judd et al., 2012); im Pilot streut es so stark wie eine Wiederholung.
2. **Seeds:** Trotz Seed 42 weichen Wiederholungen um bis zu 45 Prozentpunkte ab (Atil et al., 2024), daher je Paar ein eigener Seed.
3. **Interaktion:** Status × Mechanismus ist damit nicht abgedeckt; für 20 Prozentpunkte Unterschied wären etwa 64 Paare je Mechanismus nötig.

5 Kosten pro Lauf

MECHANISMUS	60 TURNS	100 TURNS	LÄUFE	SUMME
Score	1,00 $	1,70 $	192	326 $
Orchestrator	0,50–0,54 $	0,88 $	192	170 $
Quality	1,25 $	2,13 $	192	408 $
Blind-Quality	1,25 $	2,13 $	192	408 $
Round Robin	0,40 $	0,68 $	nicht geplant	
Hauptstudie			768	1.312 $

Vier Agenten, gpt-5-mini; 100 Turns mit Faktor 1,7 aus den gemessenen 60-Turn-Kosten hochgerechnet.

6 Literatur

- Albers, C., & Lakens, D. (2018). When power analyses based on pilot data are biased: Inaccurate effect size estimators and follow-up bias. **Journal of Experimental Social Psychology, 74**, 187–195. doi.org/10.1016/j.jesp.2017.09.004
- Atil, B. et al. (2024). **Non-determinism of „deterministic" LLM settings**. arXiv:2408.04667. arxiv.org/abs/2408.04667
- Browne, R. H. (1995). On the use of a pilot sample for sample size determination. **Statistics in Medicine, 14**(17), 1933–1940. doi.org/10.1002/sim.4780141709
- Cohen, J. (1988). **Statistical power analysis for the behavioral sciences** (2. Aufl.). Lawrence Erlbaum.
- Dunn, O. J. (1961). Multiple comparisons among means. **Journal of the American Statistical Association, 56**(293), 52–64. doi.org/10.1080/01621459.1961.10482090
- Faul, F., Erdfelder, E., Lang, A.-G., & Buchner, A. (2007). G*Power 3: A flexible statistical power analysis program for the social, behavioral, and biomedical sciences. **Behavior Research Methods, 39**(2), 175–191. doi.org/10.3758/BF03193146
- Judd, C. M., Westfall, J., & Kenny, D. A. (2012). Treating stimuli as a random factor in social psychology. **Journal of Personality and Social Psychology, 103**(1), 54–69. doi.org/10.1037/a0028347
- Lakens, D. (2022). Sample size justification. **Collabra: Psychology, 8**(1), 33267. doi.org/10.1525/collabra.33267
- Lakens, D., Scheel, A. M., & Isager, P. M. (2018). Equivalence testing for psychological research: A tutorial. **Advances in Methods and Practices in Psychological Science, 1**(2), 259–269. doi.org/10.1177/2515245918770963