

Projektbericht

Multi-Persona AI Discussion System

Motivation, Entwicklungsweg und Architektur

Jan-Niclas Loosen Simon Szulik

Universität Trier, Fachbereich IV / Softwaretechnik

Inhaltsverzeichnis

1	Einleitung und Projektidee.....	3
2	Phase 1: Der Prototyp Specificat.....	3
2.1	Single Prompt vs. Multi Prompt.....	4
2.2	One Summary vs. Multi Summary.....	5
3	Phase 2: Der Neuaufbau Communicat.....	5
3.1	Wissensbasis und erste Architektur.....	6
3.2	Weitere Einbauten.....	6
3.3	Finale Architektur.....	6
4	Offene Fragen und mögliche Forschungsaspekte.....	9
4.1	Die Eval-Lücke: Wie misst man eine gute Diskussion?.....	9
4.2	Der Forschungsraum und sein „Twist“.....	9
4.3	Studienmöglichkeiten unter der Realbedingung.....	9
4.4	Weitere offene Fragen.....	10

1 Einleitung und Projektidee

Der anfängliche Gedanke des Projektes befasste sich mit den Bedürfnissen aus dem Alltag von Solo-Entwicklerinnen. Wer allein an einem Projekt arbeitet, hat niemanden, der nachfragt, widerspricht oder eine fremde Perspektive einbringt. Genau hier wollten wir ansetzen: mit einer Hilfe für das Requirements Engineering, also für das Herausarbeiten der Anforderungen eines Projektes, die vor allem auf jene Punkte aufmerksam macht, die einem selbst gar nicht bewusst sind. Im besten Fall führt sie über die eigenen gedanklichen Grenzen hinaus und stellt die unbequemen Fragen, die man sich allein nicht stellt.

Schnell merkten wir, dass diese Idee nicht an die Softwareentwicklung gebunden ist. Was die Beiträge prägt, sind nicht die IT-Themen an sich, sondern die Personas, die in das Gespräch mit eingebunden werden. Tauscht man die Rollen aus, lässt sich dasselbe Prinzip auf nahezu beliebige Themen übertragen, von einer Produktidee über eine Studienentscheidung bis zu einer strategischen Frage oder alltäglichen Gedanken. Aus dem Spezialwerkzeug für Anforderungen wurde so nach und nach der Gedanke eines allgemeinen Diskussionswerkzeugs, das verschiedene Blickwinkel auf eine Sache zusammenbringt.

Mit der Zeit verschob sich das Ziel weg von der rein technischen Umsetzung hin zum generellen Umgang mit LLMs. Es ging uns nicht mehr nur darum, möglichst viele Perspektiven einzusammeln, sondern darum, eine möglichst menschliche Diskussion zu simulieren und auszuprobieren, wie sich der Umgang mit einem solchen Werkzeug überhaupt anfühlt. Eine Runde, in der alle gleichzeitig reden, niemand auf den anderen eingeht oder eine einzige Stimme alles dominiert, ist weder angenehm noch produktiv. Wir wollten also nicht irgendeine, sondern eine glaubwürdige Gesprächssituation schaffen.

Damit rückte eine Frage in den Mittelpunkt, die wir anfangs unterschätzt hatten: Wie sind Gespräche eigentlich aufgebaut? Ein Einblick in die NLP-Welt und die Gesprächsanalyse zeigt, dass scheinbar spontanes Reden in Wirklichkeit erstaunlich geordnet ist. Es gibt wiederkehrende Muster dafür, wer wann das Wort ergreift, wie aus einer Frage eine Antwort wird, wie Missverständnisse repariert werden und wie man Widerspruch höflich abfedert, statt ein nacktes Nein hinzuwerfen. Dazu kommt die Frage, wie Menschen überhaupt mit Sprachmodellen umgehen und wo deren typische Schwächen liegen, etwa die Neigung, allem zuzustimmen, oder das Abdriften aus der zugewiesenen Rolle. Aus beidem ergeben sich Best Practices, die wir gesichtet haben, von Prompting-Techniken bis zu Erkenntnissen über Gruppenverhalten, in dem Gruppen mal klüger sind als der Einzelne und mal dem Gruppendenken erliegen.

Aus diesen Überlegungen wuchs schließlich die übergeordnete Frage, die das Projekt bis heute begleitet: Hat die Natürlichkeit einer Diskussion tatsächlich Einfluss darauf, wie nützlich sie ist? Und durch das ganze Vorhaben zieht sich eine Spannung, die uns noch oft begegnen wird, nämlich die zwischen der Vielfalt der Perspektiven auf der einen und der Entscheidungsfähigkeit und Effizienz auf der anderen Seite. Die folgenden Kapitel zeichnen nach, wie wir uns dieser Frage Schritt für Schritt genähert haben.

2 Phase 1: Der Prototyp Specificat

In der ersten Phase ging es uns vor allem darum, die Grundidee überhaupt erfahrbar zu machen. Unser Prototyp „Specificat“ war bewusst als Experimentierfeld konzipiert. Mehrere Personas sollten gemeinsam mit der Nutzerin oder dem Nutzer ein Projekt diskutieren und wir wollten herausfinden, ob daraus ein sinnvoller Mehrwert entsteht. Technisch verfolgten wir dabei einen pragmatischen Ansatz. Ein schlanker Aufbau genügte, um die zentrale Idee zu testen. Als zugrunde liegendes Sprachmodell entschieden wir uns nach ersten Experimenten für GPT. Ausschlaggebend waren qualitative Gründe, da die Modellantworten in unseren Tests überzeugender ausfielen; des Weiteren war es die deutlich kostengünstigere Variante, die wir bis zur heutigen Version weiterverfolgen.




Abbildung 1: Erste Architektur: Jeder Experte bewertet seinen eigenen Beitrag selbst, und der höchste Wert entscheidet, wer spricht.

Die Evaluation des Prototyps erfolgte anhand von acht Testpersonen, die das Tool in einem offenen Rahmen eigenständig ausprobieren konnten. Die Bewertung beruhte damit auf einer realen Nutzungssituation ohne vorgegebene Aufgabenstruktur. Die dabei gesammelten Rückmeldungen bildeten die Grundlage für die weitere Analyse. Abbildung 1 zeigt den Ablauf des Prototyps, aus dem sich zwei zentrale Grundsatzfragen ableiten lassen.

2.1 Single Prompt vs. Multi Prompt

Die erste Frage betraf die Grundmechanik: Wie bringen wir die Personas dazu, sich sinnvoll abzuwechseln? Wir stellten zwei Wege gegenüber.

- **Variante 1, Single Prompt (Mediator):** Ein einziges Modell spielt alle Personas in einem großen Prompt zugleich, vergleicht deren mögliche Antworten und wählt die beste aus.
- **Variante 2, Multi Prompt (eigene Instanz pro Persona):** Jede Persona bekommt einen eigenen Chat mit eigenem Charakter. Jeder Beitrag erhält eine selbst vergebene Einschätzung, wie wichtig er gerade ist (ein Wert von 1 bis 10), und der höchste Wert entscheidet, wer spricht. Ein nicht gewählter Beitrag geht nicht verloren, sondern kann später wieder aufgegriffen werden.

Schon in frühen Versuchen zeigte sich die Schwäche der ersten Variante deutlich. Weil ein einziges Modell die Gedanken aller Personas zugleich vor sich hatte, verschwammen die Grenzen zwischen den Rollen; die Experten wirkten, als könnten sie einander in die Köpfe schauen, und genau die getrennten Blickwinkel, auf die es uns ankam, gingen verloren. Wir entschieden uns deshalb für die zweite Variante.

Im Test bestätigte sich, was wir erhofft, aber auch, was wir unterschätzt hatten. Die Multi-Prompt-Variante sammelte schneller ein breiteres Bild an Anforderungen, weil mehrere Personas parallel beitrugen. Zugleich entstand dieselbe ungleiche Beteiligung wie in echten Meetings: Personas mit Manager- oder Senioritätsprofil drängten sich in den Vordergrund und wiederholten sich, eine Testperson entfernte eine solche Rolle sogar, um wieder Ruhe in die Runde zu bringen. Spannend fanden wir, dass die erfundene Erfahrung einer Persona ihr Verhalten stärker prägte als ihr eigentliches Fachwissen. Die Single-Prompt-Variante kam dagegen schneller zu einem Schluss, blieb aber blasser und weniger vielfältig.

2.2 One Summary vs. Multi Summary

Die zweite Frage betraf die Zusammenfassung: eine einzige, die das gesamte Gespräch bündelt, oder eine je Persona?

Hier lag für uns die größte Überraschung. Die Zusammenfassung erwies sich als der eigentliche Schatz des Systems. Mehrere Testpersonen berichteten, dass ihre Fragen im laufenden Gespräch manchmal nur halb beantwortet wurden, in der automatischen Zusammenfassung aber plötzlich klar und auf den Punkt gebracht auftauchten. Offenbar leistet dieser Schritt im Hintergrund genau die Priorisierung und das Zuendedenken, das im Hin und Her der Diskussion sonst untergeht. Im Vergleich überzeugte uns die einzelne, integrative Zusammenfassung mehr als viele kleine. Aufwendige Memory-Konstruktionen zahlten sich kaum aus. Die schlichtere Lösung war hier die bessere.

Für den Neuaufbau nahmen wir drei Lehren mit. Erstens braucht eine echte Rollentrennung getrennte Kontexte, also eine eigene Instanz je Persona. Zweitens braucht es etwas gegen die Vormacht einzelner Stimmen, weil Statusmerkmale die Beteiligung verzerren. Und drittens fanden unsere Runden oft kein Ende, sondern drehten sich in Bewertungsschleifen; es fehlte eine ordnende Hand, die das Gespräch lenkt.

3 Phase 2: Der Neuaufbau Communicat

In der zweiten Phase wollten wir aus dem Prototyp ein tragfähiges System machen. Wir setzten nicht auf der grünen Wiese auf, sondern übernahmen die Codebasis von Specificat und bauten sie bewusst neu auf. Diesmal ging es uns nicht nur darum, dass es funktioniert, sondern dass es auf einem soliden, nachvollziehbaren Fundament steht, das wir erstmals auch theoretisch begründen konnten.

3.1 Wissensbasis und erste Architektur

Der wichtigste Schritt war, dass wir uns ernsthaft mit echten Diskussionen beschäftigten. Bevor wir das Gespräch der Agenten verbessern konnten, mussten wir verstehen, wie menschliche Diskussionen überhaupt funktionieren. Aus einer Recherche zu Gesprächsanalyse, Rollentheorie und Multi-Agent-Systemen entstand ein Baukasten aus fünf aufeinander aufbauenden Ebenen: dem Persona-Kern, dem Gedächtnis, der Gesprächsstruktur, der Interaktionsdynamik und der Orchestrierung.

Mehrere Bausteine aus der Gesprächsanalyse übersetzten wir dabei direkt in unsere Architektur:

- **Paarsequenzen (Adjacency Pairs):** Beiträge treten in erwartbaren Paaren auf, etwa Frage und Antwort oder Vorschlag und Reaktion. Jeder Agent vermerkt am Ende, welcher Paartyp gerade offen ist und wer als Nächstes gemeint sein könnte.
- **Verteilung des Rederechts (Floor-Management):** Wer das Wort hat, steuern wir aktiv, mit Regeln gegen Dauerredner, einer Bevorzugung bislang stiller Stimmen und Raum für kurze Zwischensignale.
- **Gesprächsphasen:** Das System achtet darauf, in welcher Phase eine Diskussion steckt, und passt Auswahl und Eingriffe daran an.
- **Weitere Feinheiten:** Zustimmung darf direkt kommen, Widerspruch wird abgefedert und begründet; das System korrigiert sich lieber selbst, als sich belehren zu lassen; und ein gestaffeltes Gedächtnis hält fest, was wichtig ist, ohne den Kontext zu überladen.

3.2 Weitere Einbauten

Parallel zur theoretischen Fundierung machten wir das System alltagstauglich:

- **Sprache:** Über die Anbindung von ElevenLabs bekam das System eine Stimme; zusammen mit der Spracheingabe wurde aus der reinen Textanwendung ein Werkzeug, mit dem man tatsächlich sprechen kann.
- **Mehrbenutzerbetrieb:** Aus dem Einzelplatz-Prototyp wurde eine Anwendung für mehrere Nutzer, mit Verwaltung, Export von Diskussionen und sinnvollen Nutzungsgrenzen.
- **Aufräumen:** Wir lösten uns von der Mischung aus zwei Sprachen und führten alles in PHP zusammen, was das System einfacher und wartbarer machte.

3.3 Finale Architektur

Im Kern steht eine mehrstufige Abfolge, die zwei Lehren aus Phase 1 ernst nimmt. Die erste ist die Trennung von Denken und Sprechen. Bevor ein Agent seinen sichtbaren Beitrag formuliert, überlegt er in einem eigenen, unsichtbaren Schritt, was gerade gesagt wurde, was er selbst dazu meint und welcher Ton zur Situation passt. Diese Trennung ist uns wichtig: Würden beide Schritte zusammenfallen, geriete die Überlegung leicht zur nachträglichen Rechtfertigung des bereits Gesagten statt zu einer ehrlichen Vorüberlegung.

Die zweite Lehre betrifft die Frage, wer eigentlich entscheidet, wer als Nächstes spricht. Dafür haben wir zwei Wege gebaut und gegeneinander abgewogen. In der ersten Variante schätzt jeder Agent selbst ein, wie wichtig sein Beitrag gerade ist, und ein Orchestrator wählt anschließend den passenden aus. In der zweiten Variante hält sich der Agent mit der Bewertung zurück, und der Orchestrator übernimmt sowohl die Gewichtung als auch die Auswahl.




Abbildung 2: Variante A. Die Experten priorisieren sich selbst, der Orchestrator wählt aus. Ist eine Persona direkt angesprochen, antwortet sie ohne Auswahlrunde.

In Variante A (Abbildung 2) bleibt die Bewertung bei den Experten. Der Orchestrator prüft zuerst, ob jemand direkt angesprochen wurde; falls ja, antwortet diese Persona unmittelbar. Andernfalls bewerten alle Experten parallel ihren eigenen Beitrag, und der Orchestrator kürt daraus den Gewinner.




Abbildung 3: Variante B. Der Orchestrator instruiert die Experten, priorisiert ihre Vorschläge und wählt aus.

In Variante B (Abbildung 3) liegt mehr Verantwortung beim Orchestrator: Er gibt den Experten zunächst Hinweise, sammelt ihre Vorschläge ein und entscheidet dann allein über Reihenfolge und Auswahl. Das gibt der Moderation mehr Kontrolle, kostet aber zusätzliche Schritte.

In der Praxis pendelten wir uns zwischen beiden Wegen ein und nahmen dabei viel Feinarbeit am Prompt vor. Eine anfangs eigenständige Bewertungsstufe legten wir wieder mit dem Denkschritt zusammen, weil der getrennte Aufruf den Mehraufwand an Zeit und Kosten nicht wert war. Besonders die Adjacency Pairs haben wir in zahlreichen Varianten erprobt, also die Frage, wie ein Beitrag den nächsten erwartbar macht und wer als Nächstes gemeint ist. Diese Logik lag zunächst beim Orchestrator und wanderte später zurück in den Agenten-Prompt: Wie das Gespräch insgesamt gelenkt wird, ist Sache des Orchestrators, was inhaltlich in einem einzelnen Beitrag steht, bleibt Sache der Persona.

Eng damit verbunden war die Frage, wer eine direkte Ansprache erkennt. Ein Weg ist, dass die Agenten sie selbst erzeugen und am Ende eines Beitrags unsichtbar mit ausgeben, wer als Nächstes gemeint ist. Der andere Weg ist, dass der Orchestrator die Ansprache aus dem Kontext herausliest. Der erste Weg greift jedoch nur zwischen Agenten, denn schreibt die Nutzerin selbst, fehlt dieser Hinweis. Wir sind deshalb bei einer Mischung gelandet: Solange sich Agenten untereinander adressieren, vertrauen wir auf ihre eigene Angabe; sobald die Nutzerin am Zug ist, übernimmt der Orchestrator und ordnet die Ansprache selbst zu, zuerst über eine namentliche, dann über eine inhaltliche Erkennung. So bleibt auch die Ansprache durch den Menschen korrekt zugeordnet.

Pro Gesprächsrunde fallen so mehrere Modell-Aufrufe an, mindestens drei und höchstens etwa zwei mehr, als es Personas gibt.

4 Offene Fragen und mögliche Forschungsaspekte

Mit einer fertigen Architektur verschiebt sich die spannende Frage von „Wie bauen wir das?“ hin zu „Wie gut ist es eigentlich, und wie ließe es sich gezielt verbessern?“. Daraus ergeben sich für uns mehrere Richtungen. Die unten aufgelisteten Fragen und Ideen sind dabei lediglich Anreize aus einer Vielzahl möglicher Forschungswege.

4.1 Die Eval-Lücke: Wie misst man eine gute Diskussion?

Die größte offene Stelle ist die Bewertung, denn verbessern lässt sich nur, was man auch messen kann. Drei Themenfelder bauen dabei aufeinander auf. Erstens Maße für die Qualität einer Diskussion, von klassischen Sprachmetriken über referenzfreie Verfahren wie USR und FED bis zu Kennzahlen aus der Gesprächsanalyse. Zweitens die Bewertung der Natürlichkeit, häufig durch ein zweites Sprachmodell als Gutachter, samt der bekannten Verzerrungen, die ein solcher Gutachter mitbringt. Und drittens die automatische Verbesserung, bei der ein Verfahren systematisch Prompt-Varianten ausprobiert und die besseren behält. Wir stellen uns hier eine mehrschichtige Bewertung vor, die feste Kennzahlen, ein modellgestütztes Urteil und ein menschliches Urteil miteinander kombiniert.

4.2 Der Forschungsraum und sein „Twist“

Die übergeordnete Frage lautet, ob die Natürlichkeit solcher Diskussionen ihre Effektivität beeinflusst. Mögliche Studien lassen sich auf drei Ebenen denken: beschreibend (wie misst man beides?), korrelativ (hängen sie zusammen?) und kausal (bewirkt das eine das andere?). Der eigentlich reizvolle Punkt ist aber nicht das Ob, sondern das Wie. Der Zusammenhang muss nicht linear sein; gut möglich ist ein Optimum, bei dem zu wenig Natürlichkeit roboterhaft wirkt und zu viel sich verzettelt.

4.3 Studienmöglichkeiten unter der Realbedingung

Weil unser System fertig ist und sich die Natürlichkeit nicht mehr beliebig hoch- oder herunterregeln lässt, ist ein sauberes Experiment innerhalb desselben Systems kaum möglich. Um die verschiedenen Stellschrauben und Parameter und deren Auswirkungen zu untersuchen, bedarf es weiterer Planung und einer mehrstufigen Studie. Tragfähig bleiben drei Wege: ein

Vergleich mit einem anders gebauten Werkzeug, etwa einem einzelnen Modell; eine korrelative Auswertung der ohnehin schwankenden Natürlichkeit von Sitzung zu Sitzung; und vor allem das Urteil der Nutzerinnen und Nutzer darüber, wie wirksam sie das System erleben und woran sie das festmachen. Naheliegend ist für uns eine teils explorative Einzelstudie über mehrere vorgegebene Themen, die Fragebögen, Gespräche und die Bewertung des erzeugten Ergebnisses miteinander verbindet.

4.4 Weitere offene Fragen

- **Kosten und Tempo gegen Qualität:** Pro Runde fallen mehrere Modell-Aufrufe an. Ab wann lohnt der Mehraufwand den Gewinn an Qualität nicht mehr?
- **Tragen die Messgrößen?** Verfahren wie USR oder FED stammen aus anderen Zusammenhängen und müssten erst am menschlichen Urteil in genau unserem Setting geprüft werden.
- **Wie stabil bleiben die Personas?** Reines Prompting schützt nur begrenzt davor, dass eine Rolle aus ihrem Charakter fällt; ein gezieltes Nachtrainieren könnte hier mehr leisten.
- **Wie überträgt sich das Ganze?** Offen sind Langzeit- und Gewöhnungseffekte, der Wechsel in andere Themengebiete sowie der Betrieb mit mehreren Sprachen und mehreren Menschen zugleich.